# Desarrollo de un sistema de diagnóstico asistido por computador (CAD) para la detección de tuberculosis pulmonar en radiografías de tórax

Kevin Estrada Del Valle
*Facultad de Ingeniería*
Universidad de Antioquia
Medellín, Colombia
kevin.estrada1@udea.edu.co

Juan Andrés Rivera Arango
*Facultad de Ingeniería*
Universidad de Antioquia
Medellín, Colombia
juan.rivera7@udea.edu.co

Brahiam Acosta Bedoya
*Facultad de Ingeniería*
Universidad de Antioquia
Medellín, Colombia
brahiam.acosta@udea.edu.co

***Resumen*—Este artículo presenta un sistema de diagnóstico asistido por computador para la detección de tuberculosis pulmonar en radiografías de tórax mediante aprendizaje automático tradicional. Los experimentos se realizaron con el conjunto de datos TBX11K, utilizando 8.256 imágenes etiquetadas en las categorías health, sick y tb. El flujo de procesamiento combina segmentación pulmonar, descriptores de textura y características del histograma de gradientes orientados (HOG); se seleccionaron 300 características para entrenar y comparar cinco clasificadores mediante validación cruzada anidada. La regresión logística obtuvo una exactitud balanceada fuera de muestra (OOF) de 0,8757, un F1 macro de 0,8458 y un área bajo la curva ROC (AUC-ROC) macro de 0,9720. Para la clase tuberculosis (TB), la precisión fue de 0,5788, la sensibilidad de 0,7988 y el promedio de precisión (AP) de 0,7509. El prototipo no ha sido validado clínicamente, por lo que sus resultados no deben interpretarse como evidencia de capacidad diagnóstica autónoma.**

***Palabras clave*—chest X-ray, computer-aided diagnosis, machine learning, tuberculosis detection, TBX11K.**

## 1. INTRODUCCIÓN

La tuberculosis continúa siendo un problema de salud pública y su detección representa un reto, especialmente en contextos donde un gran número de radiografías de tórax debe ser revisado y los recursos humanos disponibles son limitados [2]. La Organización Mundial de la Salud reconoce el papel de las herramientas de detección asistida por computador como apoyo en los programas de tamizaje de tuberculosis [2]. En este escenario, los sistemas de diagnóstico asistido por computador (CAD) permiten analizar imágenes médicas e identificar patrones que podrían estar relacionados con una enfermedad, sin sustituir la valoración del personal de salud. En radiografías de tórax, estos sistemas se han estudiado como herramientas de apoyo para la detección de tuberculosis, como muestra la evaluación del sistema CAD4TB v6 realizada por Murphy et al. [1].

El desarrollo de sistemas CAD para esta tarea puede abordarse mediante diferentes técnicas de aprendizaje automático. Los modelos tradicionales parten de características extraídas previamente de las imágenes, mientras que los enfoques de aprendizaje profundo aprenden representaciones directamente a partir de los datos. En los métodos tradicionales, las radiografías se describen mediante características que representan distintos aspectos visuales: la intensidad recoge los valores de los píxeles, la textura describe sus patrones y relaciones, y las características estructurales representan formas y gradientes presentes en la imagen [2]. A partir de estas representaciones pueden entrenarse clasificadores como la regresión logística, las máquinas de vectores de soporte (SVM, del inglés *support vector machines*), los árboles de decisión, Random Forest y XGBoost. La selección de características permite identificar variables relevantes y reducir la representación utilizada por los modelos, mientras que métricas como la exactitud (*accuracy*), la precisión (*precision*), la sensibilidad (*recall*), la medida F1 (*F1-score*) y el área bajo la curva ROC (AUC-ROC) permiten evaluar distintos aspectos de su desempeño.

Diversos trabajos han estudiado la detección de tuberculosis en radiografías mediante estos enfoques. Nayyar et al. [4] evaluaron algoritmos tradicionales como SVM, regresión logística, k vecinos más cercanos (KNN, del inglés *k-nearest neighbors*) y Random Forest, y reportaron tasas de clasificación de hasta 99,47 %. Win et al. [3], por su parte, combinaron características diseñadas manualmente con características obtenidas de redes preentrenadas, aplicaron selección de variables y utilizaron SVM, con una exactitud del 92,5 % en el conjunto Montgomery. También se han propuesto enfoques basados en redes convolucionales para clasificar radiografías de tórax, como los trabajos de Lakhani y Sundaram [5] y Pasa et al. [6]. Estos antecedentes muestran la variedad de representaciones y clasificadores que se han utilizado, aunque los resultados dependen de los métodos y conjuntos de datos empleados.

Entre los recursos disponibles para investigar esta tarea se encuentra TBX11K, presentado por Liu et al. [7]. Este conjunto reúne radiografías de tórax e incluye anotaciones de cajas delimitadoras para regiones asociadas con tuberculosis. Cuenta con imágenes etiquetadas para entrenamiento y validación, además de un subconjunto de prueba sin etiquetas públicas, por lo que permite estudiar la clasificación y la localización de regiones sospechosas. La disponibilidad de estas anotaciones y de distintas categorías hace posible evaluar modelos que no solo distingan imágenes con tuberculosis de imágenes sanas,

sino que también consideren otras enfermedades.

A partir de este contexto, el presente trabajo tiene como propósito desarrollar un sistema de diagnóstico asistido por computador (CAD) para la detección de tuberculosis pulmonar en radiografías de tórax mediante modelos tradicionales de aprendizaje automático basados en características de imagen. Para alcanzar este propósito, se extraen y analizan descriptores de las radiografías del conjunto TBX11K que permitan representar patrones visuales relacionados con las categorías del conjunto; con ellos se construyen y comparan distintos clasificadores tradicionales, cuyo desempeño se evalúa mediante métricas de clasificación. Finalmente, se implementa un prototipo CAD a partir del modelo seleccionado, con el fin de integrar el procesamiento de las imágenes y la generación de predicciones en una herramienta funcional de apoyo al análisis de radiografías. El estudio se centra en las categorías health, sick y tb, y examina el desempeño experimental de los modelos sin considerar sus resultados como una validación clínica.

## 2. METODOLOGÍA

El proyecto se desarrolló mediante un enfoque experimental, orientado al entrenamiento y evaluación de modelos tradicionales de aprendizaje automático para la clasificación de radiografías de tórax del conjunto de datos TBX11K. El procedimiento comprende la preparación de las imágenes, la extracción y selección de características, el entrenamiento de diferentes clasificadores y la evaluación de sus resultados.

### *2.1. Conjunto de datos*

Se utilizó TBX11K, compuesto por 11.200 radiografías de tórax distribuidas entre tres categorías: health (imágenes sanas), sick (enfermedades distintas de TB) y tb (tuberculosis). El conjunto incluye 8.400 imágenes etiquetadas para entrenamiento y validación —3.800 health, 3.800 sick y 800 tb—, además de 2.800 imágenes de prueba sin etiquetas públicas. La descarga local contenía también 502 archivos adicionales procedentes de otros conjuntos, por lo que se encontraron 3.302 archivos en la carpeta de prueba; ninguno de ellos se utilizó en los experimentos. Tras la depuración descrita en la implementación, el conjunto empleado para el modelado quedó conformado por 8.256 imágenes: 3.800 health, 3.656 sick y 800 tb.

### *2.2. Diseño experimental*

El flujo de procesamiento comprendió conversión a escala de grises, filtrado bilateral, ecualización adaptativa del histograma con limitación de contraste (CLAHE) y recorte torácico; segmentación pulmonar con PSPNet (Pyramid Scene Parsing Network); extracción de la matriz de coocurrencia de niveles de gris (GLCM), los patrones binarios locales (LBP), filtros de Gabor y HOG; y selección de 300 características mediante Random Forest. Se compararon cinco clasificadores mediante validación cruzada anidada de cinco particiones externas y tres internas. Las métricas principales se calcularon sobre predicciones fuera de muestra (out-of-fold, OOF); no se reservó un conjunto de prueba independiente. La preparación de las imágenes, la segmentación, la extracción de características, el entrenamiento y la integración del prototipo se detallan en las subsecciones siguientes de esta sección.

### *2.3. Preparación de los datos*

La preparación comenzó con la aplicación de un filtro bilateral (diámetro 9 y sigma 80), orientado a reducir el ruido sin eliminar bordes relevantes, seguida de ecualización adaptativa del histograma con limitación de contraste (CLAHE; límite de recorte 2 y cuadrícula $8 \times 8$) para mejorar el contraste local. Antes de estas operaciones se aplicó la lista canónica de exclusión del repositorio, que retiró 144 imágenes de la categoría sick por duplicación en el espacio de características. Una comprobación independiente mediante MD5 (Message-Digest Algorithm 5) identificó 126 archivos exactamente iguales; por ello, las 144 exclusiones no deben interpretarse como 144 duplicados exactos. Finalmente, las imágenes se prepararon para el recorte torácico y la segmentación pulmonar.

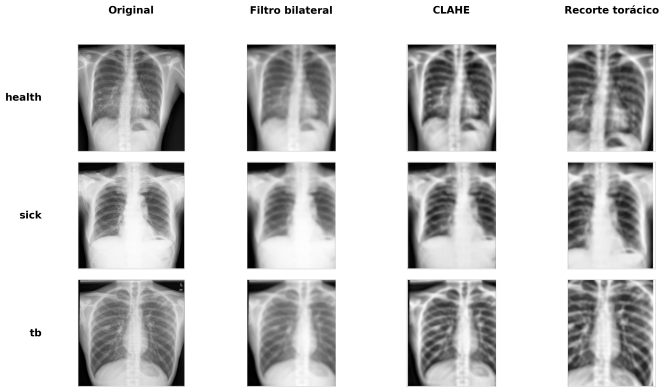



Figura 1. Preprocesamiento de radiografías de tórax.

### *2.4. Segmentación pulmonar*

Para delimitar la región pulmonar se utilizó PSPNet, una red preentrenada que produjo las probabilidades de los pulmones izquierdo y derecho a $512 \times 512$ píxeles. Las máscaras se combinaron, se umbralizaron a 0,5 y se limpiaron mediante operaciones morfológicas, conservando las componentes de al menos 0,5 % del área de la imagen. Después, la máscara se dilató 12 píxeles para definir el recorte torácico, que se redimensionó a $256 \times 256$ píxeles. Cuando PSPNet no detectó una región válida, se empleó un campo torácico central como alternativa; esto ocurrió en 18 casos (0,2 %). Para extraer las características de textura, se erosionó 8 píxeles la máscara sobre el recorte redimensionado. Así, la evaluación de cobertura de las cajas de lesión utiliza la máscara dilatada, mientras que la extracción de textura utiliza la región interior erosionada; son regiones distintas.

### *2.5. Extracción y selección de características*

Una vez procesadas las imágenes, se calcularon descriptores de textura y de estructura para representar distintos patrones visuales de las radiografías. La Tabla I resume la configuración utilizada para cada descriptor y el número de características generado.

Tabla I
CONFIGURACIÓN DE LOS DESCRIPTORES EXTRAÍDOS DE LAS RADIOGRAFÍAS.

| Descriptor | Configuración | Resumen | Características |
|---|---|---|---|
| GLCM | 64 niveles de gris; cinco propiedades y cuatro ángulos | Media y desviación estándar por propiedad, agregadas sobre los ángulos | 10 |
| LBP | $P = 24$, $R = 3$, método uniforme | Histograma de 26 bins | 26 |
| Gabor | Cuatro frecuencias y cuatro orientaciones | Media y desviación estándar de las respuestas | 32 |
| HOG | Nueve orientaciones; celdas de $32 \times 32$ píxeles; bloques de $2 \times 2$ celdas | Normalización L2-Hys | 1.764 |

En conjunto, la extracción produjo 1.860 descriptores: 68 de textura (GLCM, LBP y Gabor), 1.764 HOG y 28 variables de intensidad global y regional. Estas 28 variables de intensidad se excluyeron de la entrada del modelo principal, por lo que la representación utilizada para el modelado quedó conformada por 1.832 características: 68 de textura y 1.764 HOG. Posteriormente, se aplicó un método de selección basado en Random Forest para reducir la representación a 300 características. De las variables seleccionadas, 248 correspondieron a HOG y 52 a textura; la estabilidad media de la selección, medida mediante el índice de Jaccard entre particiones, fue de 0,6125.

### *2.6. Entrenamiento de los clasificadores*

Una vez seleccionadas las 300 variables mediante la importancia de Random Forest, se compararon tres alternativas para tratar el desbalance entre categorías: mantener la distribución original durante el entrenamiento, asignar ponderaciones a las clases mediante `class_weight` o aplicar sobremuestreo con SMOTE. La comparación se realizó mediante cinco particiones de validación cruzada y sus resultados se presentan en la Tabla II.

Tabla II
COMPARACIÓN DE ESTRATEGIAS DE BALANCEO.

| Estrategia | BalAcc | F1 macro | Recall TB |
|---|---|---|---|
| Sin ajuste | $0,8513 \pm 0,0067$ | $\mathbf{0,8583 \pm 0,0058}$ | $0,6588 \pm 0,0260$ |
| Ponderación | $\mathbf{0,8774 \pm 0,0142}$ | $0,8493 \pm 0,0124$ | $\mathbf{0,7988 \pm 0,0432}$ |
| SMOTE | $0,8673 \pm 0,0115$ | $0,8489 \pm 0,0130$ | $0,7562 \pm 0,0306$ |

Los resultados muestran que la ponderación de clases alcanzó la mayor exactitud balanceada (0,8774) y el mayor recall para TB (0,7988), mientras que el entrenamiento sin ajustes obtuvo el F1 macro más alto (0,8583). Por esta razón se seleccionó la ponderación para continuar con la comparación de clasificadores: en este problema se priorizó aumentar la detección de tuberculosis sin recurrir a muestras sintéticas, aunque esta elección implicara no maximizar todas las métricas simultáneamente.

Con la estrategia de ponderación definida, se entrenaron cinco clasificadores: regresión logística, SVM lineal, árbol de decisión, Random Forest y XGBoost. La regresión logística y SVM se ajustaron después de estandarizar las características, mientras que los modelos basados en árboles trabajaron con sus valores originales; para incorporar el tratamiento del desbalance, se utilizaron ponderaciones de clase en los modelos que lo admitían y pesos de muestra en XGBoost. La selección del modelo y el ajuste de hiperparámetros se llevaron a cabo mediante validación cruzada anidada, con cinco particiones externas y tres internas: en cada iteración, la selección de características se ajustó exclusivamente con los datos de entrenamiento y la validación interna se empleó para escoger la configuración correspondiente. Los espacios de búsqueda y las mejores configuraciones registradas se resumen en la Tabla III.

Tabla III
ESPACIOS DE BÚSQUEDA Y MEJORES HIPERPARÁMETROS REGISTRADOS.

| Modelo | Búsqueda y mejor configuración |
|---|---|
| Regresión logística | $C$: 0,003; 0,01; 0,03; 0,1; 0,3; 1. Mejor: $C = 0,1$. |
| SVM lineal | $C$: 0,0003; 0,001; 0,003; 0,01; 0,03; 0,1; 0,3; 1. Mejor: $C = 0,01$. |
| Árbol de decisión | `max_depth`: 6, 8, 12; `ccp_alpha`: 0 y 0,001. Mejor: profundidad 6 y `ccp_alpha`=0,001. |
| Random Forest | `max_features`: 0,1 y 0,2; `min_samples_leaf`: 5 y 10. Mejor: 0,1 y 10, respectivamente. |
| XGBoost | `max_depth`: 2 y 3; `learning_rate`=0,1. Mejor: profundidad 2 y tasa 0,1. |

La evaluación se realizó con las predicciones out-of-fold de las cinco particiones externas, de modo que cada imagen fue evaluada por un modelo que no había utilizado esa imagen durante el entrenamiento. Por tanto, las métricas de la Tabla I corresponden a las predicciones OOF y no evalúan los modelos reajustados posteriormente con el conjunto completo. La regresión logística mostró el mejor equilibrio entre las métricas consideradas y fue seleccionada como modelo principal, aunque la diferencia global frente a XGBoost no fue significativa (sección 4.2). Esta estimación debe interpretarse teniendo en cuenta que la elección previa de las 300 características no se repitió dentro de cada partición externa. Finalmente, los clasificadores se reajustaron utilizando el conjunto completo de datos y se guardaron para su uso posterior.

### *2.7. Integración y funcionamiento del sistema CAD*

Se desarrolló CAD-TBX11K, un prototipo con interfaz gráfica para analizar radiografías frontales de tórax. Permite cargar imágenes PNG (Portable Network Graphics) o JPG (Joint Photographic Experts Group) y ejecutar el procesamiento sin intervención manual.

Durante la inferencia, el sistema reproduce el preprocesamiento y la segmentación pulmonar descritos anteriormente, normaliza la intensidad de los píxeles dentro de la máscara pulmonar y aplica el extractor y el selector de características ajustados durante el entrenamiento. Finalmente, la regresión logística estima las probabilidades de las tres categorías: health, sick y tb. Para generar el indicador binario de TB positiva se utiliza un umbral de 0,3338 sobre la probabilidad estimada de tuberculosis. Este umbral corresponde al punto de Youden del análisis binario TB frente al resto y ofrece una sensibilidad de 0,8738 y una especificidad de 0,9069. No sustituye la decisión multiclase basada en la mayor probabilidad: por ello, el recall TB multiclase de 0,7988 reportado en la evaluación OOF es una métrica distinta. Como referencia, con umbral 0,5 la

sensibilidad y especificidad son 0,7912 y 0,9406; para alcanzar una sensibilidad objetivo de 0,9000, el umbral estimado fue 0,1921, con especificidad de 0,8553.

La interfaz presenta la clase y las probabilidades estimadas, las variables con mayor contribución, la imagen procesada y un mapa de oclusión de 6 × 6 regiones. Esta cuadrícula corresponde a la visualización integrada en el prototipo; para el análisis de interpretabilidad descrito en la Sección 4.3 se utilizó una resolución de 8 × 8 regiones. Como parte de la entrega del sistema, el prototipo se desplegó en una instancia Amazon EC2 de Amazon Web Services (AWS), desde la cual puede consultarse la aplicación web [9]. Además, para facilitar la reproducibilidad y la consulta del proceso experimental, el código fuente y los cuadernos de trabajo (notebooks) se organizaron en un repositorio público de GitHub [8].

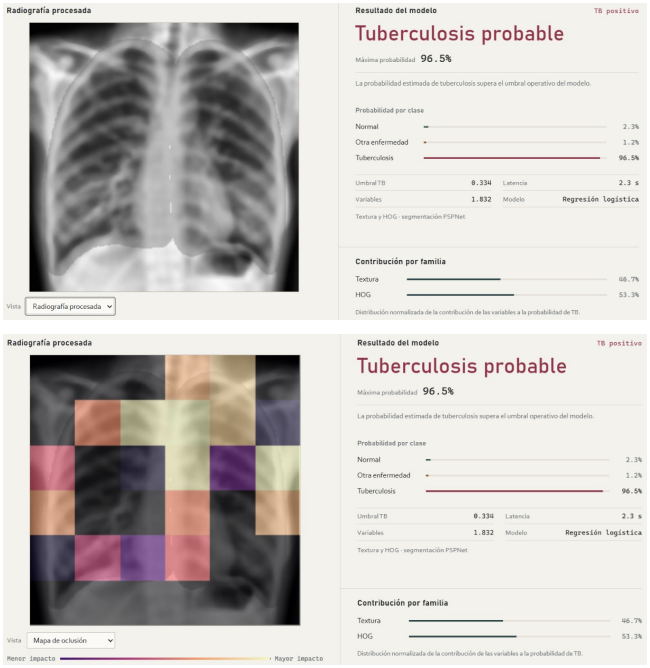



Figura 2. Prototipo CAD: (a) resultado de clasificación y (b) mapa de oclusión.

## 3. RESULTADOS

### 3.1. *Validación de la segmentación pulmonar*

Para evaluar indirectamente la delimitación pulmonar se comparó PSPNet con el método de Otsu en las 800 imágenes TB, de las cuales 799 contienen 1.211 cajas de lesiones anotadas en TBX11K. Se calculó la cobertura de las cajas por las máscaras y si el centro de cada caja quedaba dentro de la región segmentada. PSPNet obtuvo una cobertura media por imagen de 0,936, frente a 0,539 de Otsu. En ese conjunto, el 97,2 % de las imágenes alcanzó una cobertura media de cajas por imagen de al menos 0,8, frente al 15,2 % con Otsu. Para el umbral de 0,5, los porcentajes fueron 99,8 % y 59,5 %, respectivamente. El centroide de las cajas quedó dentro de la máscara en el 99,9 % de las imágenes con PSPNet y en el 73,1 % con Otsu. Estos resultados describen la cobertura de las anotaciones y no corresponden a métricas de solapamiento entre máscaras de referencia y predicción, como el coeficiente Dice y la intersección sobre unión (IoU, del inglés *intersection over union*), métricas de solapamiento utilizadas para evaluar segmentaciones [10]; por tanto, constituyen una comprobación indirecta y no una validación anatómica completa de la segmentación.

### 3.2. *Comparación y selección del modelo*

La Tabla I muestra que la regresión logística obtuvo la mayor exactitud balanceada (87,57 %) y F1 macro (84,58 %), con AUC-ROC macro prácticamente empatada con XGBoost (0,9720 frente a 0,9718). Se seleccionó por su mejor equilibrio y recall TB.

Tabla I
COMPARACIÓN DEL DESEMPEÑO DE LOS CLASIFICADORES MEDIANTE VALIDACIÓN CRUZADA ANIDADA (OOF).

| Clasificador | Accuracy | Bal. acc. | F1 macro | Recall TB | AUC macro | AP TB | Esp. TB |
|---|---|---|---|---|---|---|---|
| Regresión logística | 0,9037 | 0,8757 | 0,8458 | 0,7988 | 0,9720 | 0,7509 | 0,9376 |
| SVM lineal | 0,8960 | 0,8698 | 0,8342 | 0,7988 | 0,9601 | 0,6286 | 0,9272 |
| XGBoost | 0,9036 | 0,8601 | 0,8393 | 0,7400 | 0,9718 | 0,7047 | 0,9426 |
| Random Forest | 0,8882 | 0,8053 | 0,8089 | 0,5738 | 0,9601 | 0,6341 | 0,9603 |
| Árbol de decisión | 0,7930 | 0,7487 | 0,7103 | 0,6275 | 0,8757 | 0,3281 | 0,8624 |
| Dummy | 0,4603 | 0,3333 | 0,2101 | 0,0000 | 0,5000 | 0,0969 | – |

El IC del 95 % por bootstrap estratificado para la regresión logística fue [0,8648; 0,8857] para exactitud balanceada y [0,7700; 0,8262] para recall TB. Al analizar específicamente la categoría de tuberculosis (tb), la regresión logística obtuvo una precisión de 57,88 % y un recall de 79,88 %, con un F1 de 67,12 % y un AP para TB de 0,7509. Esto significa que el modelo logró identificar una proporción importante de las imágenes con tuberculosis, aunque también clasificó como tuberculosis imágenes que pertenecían a otras categorías.

La matriz de confusión (Tabla II) permite observar con mayor detalle estos errores. De las imágenes etiquetadas como tuberculosis, 100 fueron clasificadas como sick y 61 como health. También se observa que 379 imágenes de la categoría sick y 86 de health fueron clasificadas como tuberculosis. En total, 465 imágenes de otras categorías se predijeron como TB: el 81,5 % correspondió a sick y el 18,5 % a health, lo que explica la precisión de 57,88 %. Esta distribución indica que la principal fuente de falsos positivos fue la confusión entre TB y otras enfermedades agrupadas en sick, más que la clasificación de imágenes sanas como TB. La comparación estadística de McNemar con corrección de Holm no mostró diferencias globales entre regresión logística y XGBoost ($p = 1{,}0000$), mientras que sí encontró una diferencia entre regresión logística y SVM ($p = 0{,}0024$). Al restringir la comparación a los casos TB, la diferencia entre regresión logística y SVM no fue significativa ($p = 0{,}9062$), mientras que sí lo fue frente a XGBoost ($p = 0{,}0003$). Estos contrastes deben interpretarse junto con las métricas por clase y no como una superioridad uniforme en todos los criterios.

El análisis de umbrales permite examinar el compromiso entre sensibilidad y especificidad en la detección binaria de TB frente al resto. Con el umbral convencional de 0,5 se obtuvo una sensibilidad de 0,7912 y una especificidad de 0,9406. Al utilizar el umbral de Youden (0,3338), la sensibilidad aumentó a 0,8738 y la especificidad fue de 0,9069. Para alcanzar una

sensibilidad de 0,9000, el umbral disminuyó a 0,1921 y la especificidad fue de 0,8553. Por tanto, recuperar más casos TB implica aceptar más falsos positivos. Estos puntos operativos se estimaron a partir de predicciones OOF y requieren validación independiente; corresponden a la decisión binaria TB frente al resto y no modifican las métricas de clasificación multiclase de la Tabla I.

Tabla II
MATRIZ DE CONFUSIÓN OOF NORMALIZADA POR FILA DE LA REGRESIÓN LOGÍSTICA ( %).

| Real / predicha | health | sick | tb |
|---|---|---|---|
| health | 95,7 | 2,0 | 2,3 |
| sick | 2,5 | 87,1 | 10,4 |
| tb | 7,6 | 12,5 | 79,9 |

*Nota:* cada fila expresa la distribución porcentual de las predicciones para una clase real.

### *3.3. Interpretabilidad del modelo*

Para analizar las variables que influyen en las predicciones se estudiaron los coeficientes estandarizados de la regresión logística seleccionada. De las 300 características seleccionadas, 248 correspondieron a HOG y 52 a textura. Entre las variables con mayor magnitud de coeficiente se encontraron descriptores Gabor y GLCM, como Gabor de frecuencia 0,3 y orientación 135°, homogeneidad GLCM y correlación GLCM. Aunque algunas variables de textura aparecen entre las contribuciones individuales más altas, la composición del conjunto seleccionado muestra que HOG representa la mayor parte de las variables utilizadas. Sin embargo, la magnitud de los coeficientes indica su influencia dentro del modelo y no demuestra que correspondan directamente a lesiones o signos radiológicos específicos de tuberculosis.

Adicionalmente, se analizaron las contribuciones de las características en ejemplos de predicciones correctas e incorrectas y se implementó una prueba de oclusión por regiones de la imagen. Estas pruebas permitieron explorar cómo cambia la predicción al modificar la información visual disponible, aunque sus resultados deben interpretarse como herramientas de análisis del comportamiento del clasificador y no como una explicación clínica de sus decisiones.

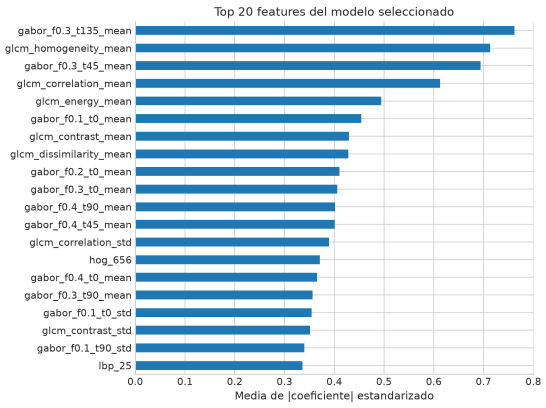



Figura 3. Veinte características con mayor magnitud de coeficiente estandarizado en el modelo seleccionado.

### *3.4. Limitaciones*

Entre las limitaciones del trabajo se encuentran la utilización de un único conjunto de datos, la ausencia de identificadores del paciente y la falta de una evaluación externa. Las métricas principales proceden de predicciones OOF y no de un conjunto de prueba independiente; además, los modelos finales se reajustaron con las 8.256 imágenes disponibles. La selección previa del número y método de características tampoco se volvió a optimizar dentro de cada fold externo. El umbral binario de 0,3338 se seleccionó a partir de las predicciones OOF y requiere validación independiente antes de considerarse un punto operativo generalizable. La validación de la segmentación se basó en la cobertura de cajas de lesión y no en máscaras anatómicas de referencia, por lo que no permite calcular Dice o IoU ni garantiza que la región erosionada usada para textura cubra toda la extensión periférica de las lesiones. Además, las categorías sick y tb agrupan condiciones heterogéneas. Finalmente, no se realizó un estudio clínico ni una evaluación prospectiva; por tanto, el prototipo no está validado clínicamente, no sustituye el juicio clínico y sus resultados no deben interpretarse como diagnóstico autónomo.

## 4. CONCLUSIONES

Los resultados muestran que las características extraídas de radiografías permiten diferenciar las categorías de TBX11K. La regresión logística presentó el mejor equilibrio entre las métricas, aunque su diferencia global frente a XGBoost no fue significativa (sección 4.2). Para la clase TB, la precisión fue menor debido principalmente a la confusión con imágenes de otras enfermedades, lo que evidencia la dificultad de distinguir hallazgos específicos de tuberculosis.

El desempeño corresponde a un resultado experimental sobre TBX11K, no a una validación clínica. La falta de evaluación externa e identificadores de pacientes limita su generalización; el prototipo no sustituye el juicio clínico ni debe utilizarse como diagnóstico autónomo.

### *4.1. TRABAJO FUTURO*

Como trabajo futuro se requiere una validación externa en instituciones y equipos distintos, con particiones por paciente cuando existan identificadores. También deberán estudiarse la calibración y el ajuste del umbral, así como métodos especializados para distinguir TB de otras enfermedades, evaluando el impacto de falsos positivos y falsos negativos.

## REFERENCIAS


[1] K. Murphy et al., "Computer aided detection of tuberculosis on chest radiographs: An evaluation of the CAD4TB v6 system," *Scientific Reports*, vol. 10, Art. no. 5492, 2020.

[2] World Health Organization, *Use of Computer-Aided Detection Software for Tuberculosis Screening: WHO Policy Statement*, 2025.

[3] K. Y. Win, N. Maneerat, K. Hamamoto, and S. Sreng, "Hybrid Learning of Hand-Crafted and Deep-Activated Features Using Particle Swarm Optimization and Optimized Support Vector Machine for Tuberculosis Screening," *Applied Sciences*, vol. 10, no. 17, Art. no. 5749, 2020.

[4] A. Nayyar, R. Shrivastava, and S. Jain, "A Framework for Two-class Classification of Pulmonary Tuberculosis using Artificial Intelligence," *Current Medical Imaging*, vol. 21, Art. no. e15734056343819, 2025, doi: 10.2174/0115734056343819250307040956.

[5] P. Lakhani and B. Sundaram, “Deep Learning at Chest Radiography: Automated Classification of Pulmonary Tuberculosis by Using Convolutional Neural Networks,” *Radiology*, vol. 284, no. 2, pp. 574–582, 2017.

[6] F. Pasa et al., “Efficient Deep Network Architectures for Fast Chest X-Ray Tuberculosis Screening and Visualization,” *Scientific Reports*, vol. 9, Art. no. 6268, 2019.

[7] Y. Liu, Y.-H. Wu, Y. Ban, H. Wang, and M.-M. Cheng, “Rethinking Computer-Aided Tuberculosis Diagnosis,” in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pp. 2646–2655, 2020.

[8] K. Estrada Del Valle, J. A. Rivera Arango, and B. Acosta Bedoya, “CAD_TBX11K: código fuente y notebooks del proyecto,” GitHub. [En línea]. Disponible en: https://github.com/KevEstr/CAD_TBX11K/tree/main/notebooks

[9] K. Estrada Del Valle, J. A. Rivera Arango, and B. Acosta Bedoya, “CAD-TBX11K: prototipo desplegado,” Amazon Web Services (AWS), instancia Amazon EC2. [En línea]. Disponible en: http://3.134.162.144/

[10] A. A. Taha and A. Hanbury, “Metrics for evaluating 3D medical image segmentation: analysis, selection, and tool,” *BMC Medical Imaging*, vol. 15, Art. no. 29, 2015, doi: 10.1186/s12880-015-0068-x.