01 — Carga de Datos

Pipeline CAD-TBX11K | Diagnóstico Asistido por Computador en Tuberculosis

Este notebook corresponde a la primera etapa del pipeline. Su propósito es configurar el entorno, descargar el dataset **TBX11K** desde Kaggle y construir el **DataFrame base** que será utilizado por todos los notebooks siguientes.

Objetivo

Construir un DataFrame con la siguiente estructura:

Columna	Descripción
`image_path`	Ruta absoluta al archivo de imagen
`class_name`	Nombre de la clase: `health`, `sick` o `tb`
`label`	Etiqueta numérica: 0, 1 o 2
`ancho`	Ancho original de la imagen en píxeles
`alto`	Alto original de la imagen en píxeles
`modo`	Modo de color PIL (p. ej. `RGB`, `L`)

Clases del dataset

Clase	Etiqueta	Descripción
`health`	0	Radiografía de persona sana
`sick`	1	Persona enferma, pero no diagnosticada con TB
`tb`	2	Tuberculosis confirmada

Referencias

- Dataset TBX11K: https://mmcheng.net/tb/
- kagglehub: https://github.com/Kaggle/kagglehub

0. Configuración del entorno

In [2]:
```
# Se agrega el directorio raíz del proyecto al path de Python para poder importar
# el módulo `src` desde cualquier ubicación de ejecución del notebook.
# Referencia: https://docs.python.org/3/library/sys.html#sys.path

import sys, os, warnings
import pandas as pd
import importlib

warnings.filterwarnings('ignore')
...

# La carpeta raíz del proyecto se ubica dos niveles por encima de `notebooks/`
PROJECT_ROOT = os.path.abspath(os.path.join(os.getcwd(), '..'))
if PROJECT_ROOT not in sys.path:
    sys.path.insert(0, PROJECT_ROOT)

print(f'Raíz del proyecto: {PROJECT_ROOT}')
```

```
Raíz del proyecto: c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k
```

In [2]:
```python
# Se importan las funciones del módulo `cad_tbx11k.data` que encapsulan
# toda la lógica de carga y construcción del DataFrame base.
# Cada función está documentada en cad_tbx11k/data.py.

import warnings
warnings.filterwarnings('ignore')

from src.data import (
    setup_kaggle_credentials,   # Configura kaggle.json en ~/.kaggle/
    download_dataset,           # Descarga el dataset TBX11K via kagglehub
    get_data_root,              # Verifica y retorna la ruta TBX11K/
    map_dataset_structure,      # Mapea la estructura completa de imgs/
    build_base_dataframe,       # Construye el DataFrame base etiquetado
    LABEL_MAP, PALETTE,
)

# Configuración central del pipeline: definida una sola vez en src/config.py
from src.config import N_MUESTRA
from src.visualization import (
    set_publication_style,
    plot_dataset_distribution,
    plot_image_metadata,
)
```

1. Configuración de credenciales Kaggle

In [3]:
```python
# Se configuran las credenciales de Kaggle copiando kaggle.json a ~/.kaggle/.
# Si el archivo ya existe en el destino, la copia se omite automáticamente.
# Para obtener el archivo: kaggle.com → Settings → API → Create New Token
# Documentación: https://www.kaggle.com/docs/api

# setup_kaggle_credentials()
```

2. Descarga del dataset

In [4]:
```python
# Opción 1:
# Se descarga el dataset TBX11K mediante kagglehub.
# Si el dataset ya está en caché local, la descarga se omite.
# La variable `download_path` apunta al directorio raíz de la descarga.
# Referencia: https://github.com/Kaggle/kagglehub
# download_path = download_dataset()
# DATA_ROOT     = get_data_root(download_path)


# Opción 2:
# Dataset descargado manualmente en data/TBX11K/ dentro del proyecto.
# PROJECT_ROOT se calcula automáticamente — funciona en cualquier máquina.
DATA_ROOT = os.path.join(PROJECT_ROOT, "data", "TBX11K")

print(f"DATA_ROOT : {DATA_ROOT}")
print(f"Existe    : {os.path.exists(DATA_ROOT)}")
```

```
DATA_ROOT : c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k\data\TBX11K
Existe    : True
```

3. Estructura completa del dataset

In [5]:
```python
# Se mapea la estructura del directorio `imgs/` sin cargar ninguna imagen.
# Esto permite entender qué particiones contiene el dataset antes de filtrar.
# Se trabaja solo con health, sick y tb (subconjunto etiquetado).

resumen_df = map_dataset_structure(DATA_ROOT)
print(resumen_df.to_string(index=False))
print(f'\nTotal de imágenes en el dataset descargado: {resumen_df["imagenes"].sum()}')
```

```
carpeta  subcarpeta  imagenes
  extra       da+db         0
  extra mc+shenzhen         0
 health           -      3800
   sick           -      3800
     tb           -       800
   test           -      3302

Total de imágenes en el dataset descargado: 11702
```

4. Construcción del DataFrame base

In [6]:

```python
# Se cargan únicamente las imágenes etiquetadas (health, sick, tb).
# Para cada imagen se registran ruta, clase, etiqueta y dimensiones originales.
# Las imágenes corruptas o ilegibles se omiten con una advertencia.
# Referencia PIL: https://pillow.readthedocs.io/en/stable/reference/Image.html

df_base = build_base_dataframe(DATA_ROOT)

# N_MUESTRA controla cuántas imágenes por clase se cargan en df_base.
# Está definida UNA sola vez en src/config.py y ya se importó más arriba:
# cámbiala ahí y el nuevo valor aplica a todo el pipeline (02, 03, 04, 05).
# Con None se usa el dataset completo (~8.400 imágenes).

if N_MUESTRA:
    df_base = pd.concat([
        df_base[df_base['class_name'] == clase].sample(
            min(N_MUESTRA, len(df_base[df_base['class_name'] == clase])),
            random_state=42
        )
        for clase in LABEL_MAP
    ]).reset_index(drop=True)
    print(f'Modo prueba: {len(df_base)} imágenes ({N_MUESTRA} por clase)')
else:
    print(f'Dataset completo: {len(df_base)} imágenes')

print()
print(df_base['class_name'].value_counts())
print()
print(df_base.head())
```

```
Dataset cargado: 8400 imágenes en 3 clases (0 omitidas por error).
class_name
health    3800
sick      3800
tb         800
Dataset completo: 8400 imágenes

class_name
health    3800
sick      3800
tb         800
Name: count, dtype: int64

                                          image_path class_name  label  ancho  \
0  c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k...     health      0    512
1  c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k...     health      0    512
2  c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k...     health      0    512
3  c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k...     health      0    512
4  c:\Users\estra\Desktop\Tuberculosis\cad-tbx11k...     health      0    512

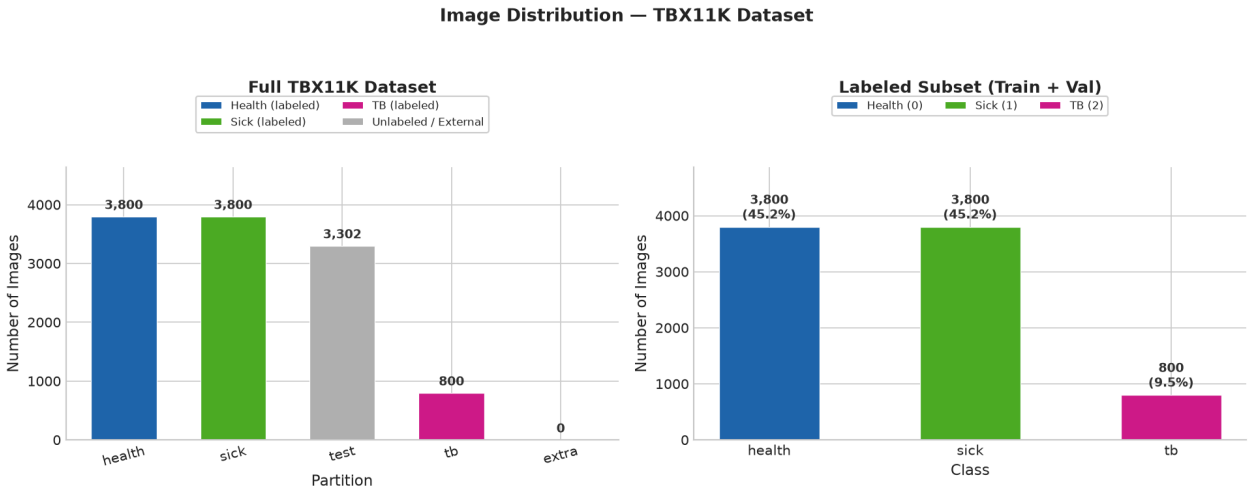
   alto modo
0   512  RGB
1   512  RGB
2   512  RGB
3   512  RGB
4   512  RGB
```

5. Visualización de la distribución del dataset

In [7]:
```
# Se genera el panel de distribución del dataset completo y del subconjunto
# etiquetado. Los porcentajes sobre las barras permiten verificar el desbalance
# de clases que deberá tenerse en cuenta en la etapa de modelado.
# Para guardar la figura, descomentar la línea correspondiente dentro de la función.

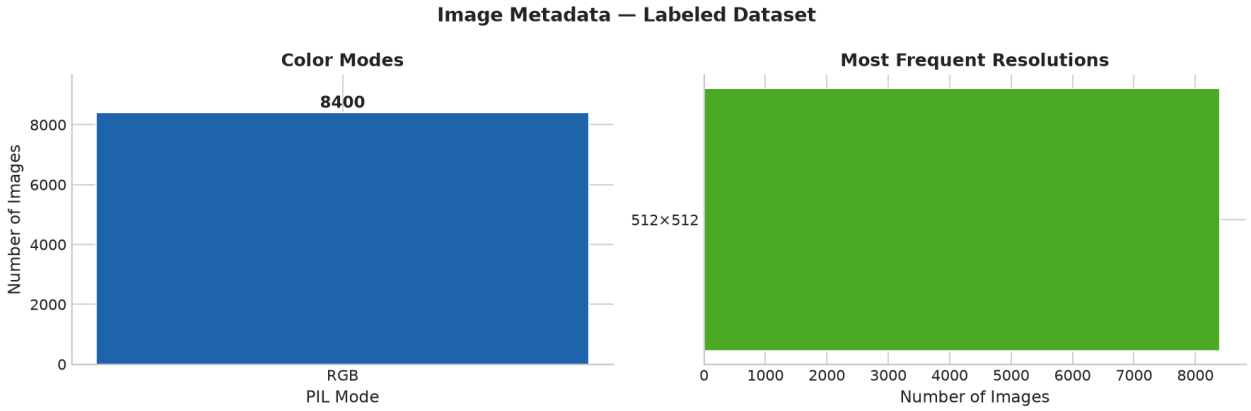
# set_publication_style()
# plot_dataset_distribution(resumen_df, df_base)

set_publication_style()
plot_dataset_distribution(resumen_df, df_base)
```



In [8]:
```
# Se visualizan los modos de color y las resoluciones más frecuentes en el dataset.
# La mayoría de las imágenes TBX11K son RGB; se convierten a escala de grises
# durante el preprocesamiento (notebook 03).
# Resoluciones heterogéneas justifican el resize a 256×256 del pipeline.

plot_image_metadata(df_base)
```



6. Resumen del DataFrame base

In [9]:
```
# Se imprime un resumen estadístico de las dimensiones originales de las imágenes.
# La variabilidad en ancho y alto confirma la necesidad de normalizar el tamaño.

from IPython.display import display, Markdown

# Resumen exploratorio del conjunto de imágenes

display(Markdown("### Distribución por clase"))
display(
    df_base['class_name']
    .value_counts()
    .rename_axis('Clase')
    .reset_index(name='Cantidad')
)

display(Markdown("### Estadísticas de dimensiones (px)"))
```

```
display(
    df_base[['ancho', 'alto']]
    .describe()
    .round(1)
)
```

Distribución por clase

	Clase	Cantidad
0	health	3800
1	sick	3800
2	tb	800

Estadísticas de dimensiones (px)

	ancho	alto
count	8400.0	8400.0
mean	512.0	512.0
std	0.0	0.0
min	512.0	512.0
25%	512.0	512.0
50%	512.0	512.0
75%	512.0	512.0
max	512.0	512.0

Salida de este notebook

El DataFrame `df_base` queda disponible en memoria para ser utilizado directamente en los notebooks siguientes ejecutados en la misma sesión, o bien puede exportarse:

```
df_base.to_csv('../df_base.csv', index=False)
```

Siguiente etapa: `02_Analisis_Exploratorio.ipynb`

In [10]:
```
df_base.to_csv('../data/df_base.csv', index=False)
```