02 — Análisis Exploratorio

Pipeline CAD-TBX11K | Diagnóstico Asistido por Computador en Tuberculosis

Este notebook explora visualmente el dataset para entender qué información contienen las radiografías **antes de cualquier preprocesamiento**. Se trabaja intencionalmente sobre imágenes crudas para separar el efecto de los datos del efecto del pipeline.

Preguntas que se responden

1. ¿Las radiografías de distintas clases presentan diferencias visibles a simple vista?
2. ¿Existen diferencias en la distribución de intensidad entre clases?
3. ¿Qué métricas básicas de intensidad tienen mayor capacidad discriminativa?

Métricas de intensidad analizadas

Métrica	Descripción
`mean`	Brillo promedio global de la imagen
`std`	Variabilidad de brillo — tejidos heterogéneos producen mayor std
`contrast`	Diferencia entre el píxel más brillante y el más oscuro
`entropy`	Desorden del histograma — lesiones TB aumentan la entropía

0. Configuración del entorno

In [1]:
```
# Se configura el path del proyecto y se importan las funciones del framework.

import sys, os, warnings
warnings.filterwarnings('ignore')
import pandas as pd
from pathlib import Path
import numpy as np

PROJECT_ROOT = os.path.abspath(os.path.join(os.getcwd(), '..'))
if PROJECT_ROOT not in sys.path:
    sys.path.insert(0, PROJECT_ROOT)


from src.data import (
    download_dataset, get_data_root, build_base_dataframe,
    LABEL_MAP, PALETTE,
)

# Configuración central del pipeline: definida una sola vez en src/config.py
from src.config import N_INTENSIDAD
from src.visualization import (
    set_publication_style,
    plot_sample_images,
    plot_intensity_histograms,
    compute_intensity_stats,
    plot_intensity_metrics,
)

set_publication_style()
print('Entorno configurado correctamente.')
```

```
Entorno configurado correctamente.
```

1. Carga del DataFrame base

In [2]:
```
# Se carga el DataFrame base desde data/df_base.csv.
# Si aún no existe, ejecutar primero el notebook 01 para generarlo.

CSV_PATH = Path('..') / 'data' / 'df_base.csv'

if CSV_PATH.exists():
    df_base = pd.read_csv(CSV_PATH)
    print(f'DataFrame cargado desde: {CSV_PATH.resolve()}')
    print(f'Total imágenes: {len(df_base)}')
else:
    print(f'[ERROR] No se encontró: {CSV_PATH.resolve()}')
    print('Ejecuta primero el notebook 01 para generar df_base.csv')

print()
print(df_base['class_name'].value_counts())
```

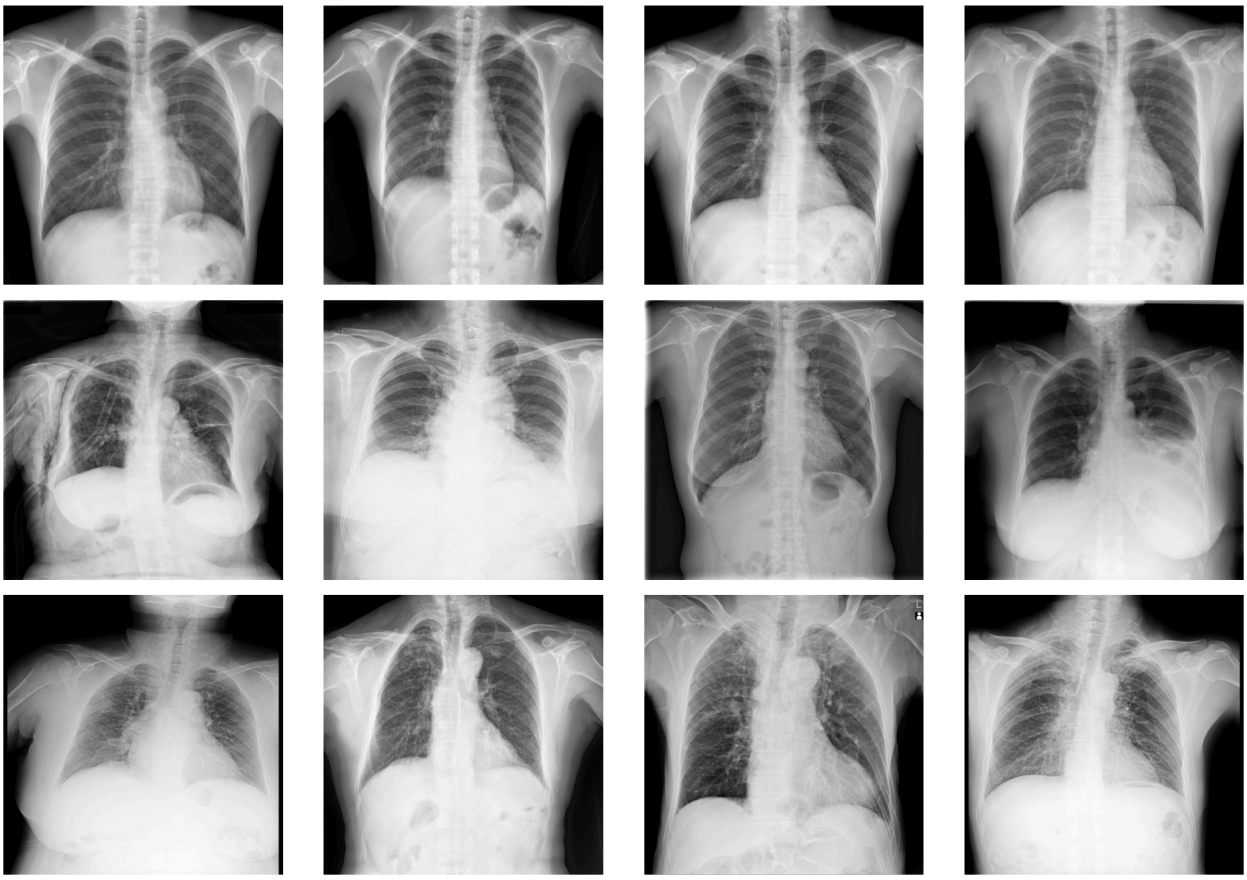
```
DataFrame cargado desde: C:\Users\estra\Desktop\Tuberculosis\cad-tbx11k\data\df_base.csv
Total imágenes: 8400

class_name
health    3800
sick      3800
tb         800
Name: count, dtype: int64
```

2. Visualización de ejemplos por clase

In [3]:
```
# Se muestran 4 radiografías por clase sin ningún preprocesamiento.
# El objetivo es calibrar la percepción visual antes de cuantificar las diferencias.
# Las imágenes se cargan en escala de grises con OpenCV.
# Referencia cv2.imread: https://docs.opencv.org/4.x/d4/da8/group__imgcodecs.html

plot_sample_images(df_base, n=4, random_state=42)
```

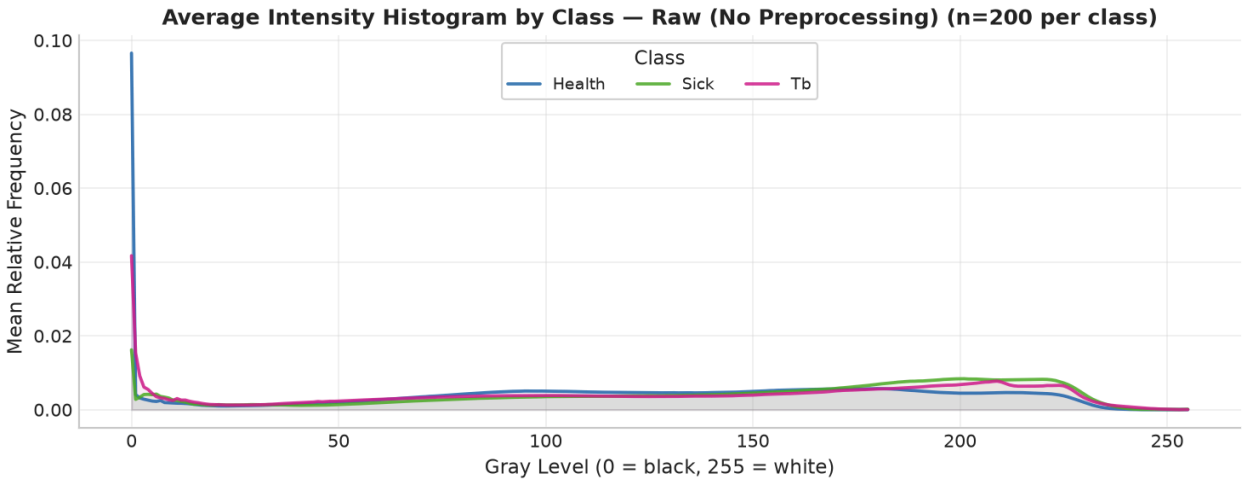


3. Histogramas de intensidad por clase — imágenes sin preprocesar

In [4]:
```
# Se calcula el histograma de intensidad promedio por clase.
# n_hist se ajusta automáticamente si el modo prueba tiene menos imágenes disponibles.
# Un histograma promedio reduce el efecto de variaciones individuales y muestra
# la tendencia central de la distribución de brillo por clase.
# Si las curvas difieren entre clases, la intensidad contiene información discriminativa.

N_HIST = min(N_INTENSIDAD, len(df_base[df_base['class_name'] == 'health']))

plot_intensity_histograms(df_base, n_hist=N_HIST, preprocessed=False, random_state=42)
```



4. Métricas de intensidad por clase — cálculo tabular

In [5]:
```
# Se calculan las cuatro métricas sobre n imágenes por clase.
# La tabla de promedios permite comparar cuantitativamente las diferencias entre clases
# antes de visualizarlas mediante los gráficos de distribución.

N_HIST = min(N_INTENSIDAD, len(df_base[df_base['class_name'] == 'health']))

stats_df = compute_intensity_stats(df_base, n_hist=N_HIST, random_state=42)

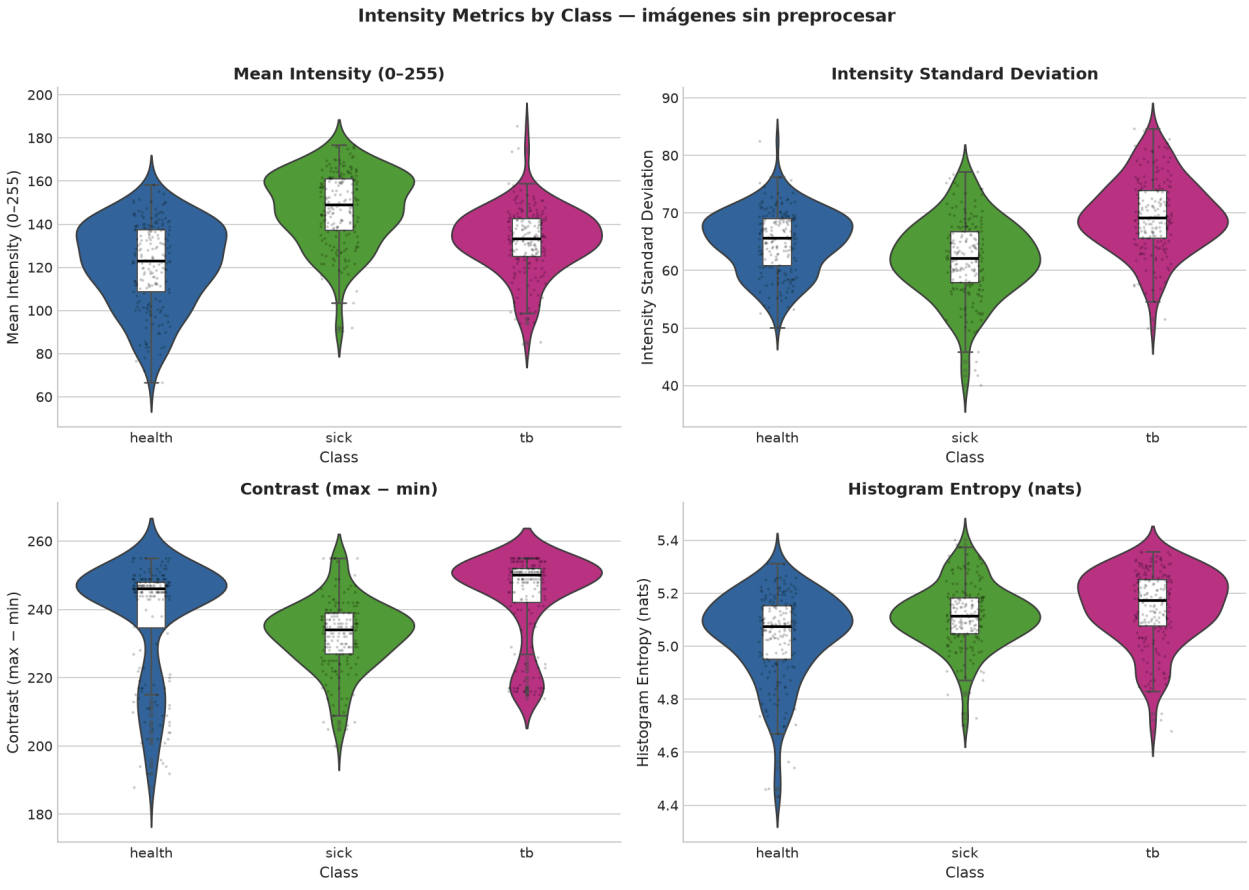
print(f'Promedios por clase (imágenes sin preprocesar, n={N_HIST} por clase):')
print(stats_df.groupby('class_name')[['mean','std','contrast','entropy']].mean().round(3).to_string())
```

```
Promedios por clase (imágenes sin preprocesar, n=200 por clase):
               mean     std  contrast  entropy
class_name
health      121.213  65.052    238.08    5.037
sick        147.355  62.000    232.30    5.113
tb          132.262  69.497    244.00    5.147
```

5. Distribución de métricas por clase

In [6]:
```
# Se visualizan las distribuciones mediante violin plots superpuestos con
# box plots y strip plots. Esta combinación muestra simultáneamente:
#   - la forma de la distribución (violín)
#   - mediana, cuartiles y valores atípicos (caja)
#   - las observaciones individuales (puntos)

plot_intensity_metrics(stats_df, title_suffix='imágenes sin preprocesar')
```



6. Tabla resumen de métricas

In [7]:
```
# Se consolida una tabla comparativa de métricas por clase con media y desviación
# estándar. Esta tabla sirve como línea base (before) para comparar con los
# resultados post-preprocesamiento en el notebook 03.

resumen = stats_df.groupby('class_name')[['mean', 'std', 'contrast', 'entropy']] \
                  .agg(['mean', 'std'])
```

```
resumen.columns = ['_'.join(col) for col in resumen.columns]
resumen = resumen.round(3)

print('Tabla resumen de métricas de intensidad (imágenes crudas):')
print(resumen)
```

```
Tabla resumen de métricas de intensidad (imágenes crudas):
            mean_mean  mean_std  std_mean  std_std  contrast_mean  \
class_name
health        121.213    19.589    65.052    5.422         238.08
sick          147.355    16.977    62.000    6.707         232.30
tb            132.262    15.496    69.497    6.323         244.00

            contrast_std  entropy_mean  entropy_std
class_name
health            16.887         5.037        0.165
sick              10.196         5.113        0.119
tb                12.680         5.147        0.137
```

Conclusiones preliminares

La tabla resume las estadísticas descriptivas obtenidas a partir de la muestra actual de imágenes por clase antes de aplicar cualquier etapa de preprocesamiento. Debido a que se trata de un análisis exploratorio, los resultados permiten identificar diferencias iniciales entre las categorías, pero no permiten establecer por sí solos la capacidad discriminativa de cada característica.

La intensidad media presenta la mayor diferencia entre las clases. Las imágenes de la clase sick registran el valor promedio más alto (147.14 ± 17.62), seguidas por tb (132.49 ± 15.17) y health (123.12 ± 19.17). Esto indica que, en esta muestra, las imágenes sick tienden a presentar niveles medios de intensidad superiores, mientras que health presenta los valores más bajos. La diferencia entre sick y health es más marcada que la diferencia entre tb y health.

La desviación estándar de intensidad presenta un comportamiento diferente. La clase tb alcanza el promedio más elevado (69.78 ± 6.27), seguida por health (65.42 ± 5.37), mientras que sick presenta el valor más bajo (62.69 ± 6.84). Esto indica una mayor variabilidad de los niveles de gris dentro de las imágenes tb de esta muestra. Sin embargo, existe cierto solapamiento entre las categorías, por lo que esta característica por sí sola no permite establecer una separación clara entre las clases.

En cuanto al contraste, tb presenta el valor medio más elevado (243.93 ± 13.38), seguido por health (238.47 ± 16.16) y sick (233.90 ± 8.93). Aunque existe una diferencia entre los valores medios, las desviaciones estándar muestran variabilidad dentro de las clases, especialmente en health y tb. Por tanto, el contraste presenta diferencias entre categorías, pero su capacidad para diferenciarlas deberá evaluarse posteriormente mediante métodos de selección de características y modelos de clasificación.

La entropía del histograma presenta valores relativamente cercanos entre las tres categorías. Las clases tb (5.133 ± 0.154) y sick (5.130 ± 0.114) presentan valores medios prácticamente iguales y ligeramente superiores a health (5.032 ± 0.167). Esto indica que la entropía presenta diferencias menores entre las clases en comparación con la intensidad media y la desviación estándar.

En conjunto, la intensidad media es la característica que presenta la diferencia más evidente entre las categorías en esta muestra, seguida por la desviación estándar de intensidad. El contraste también presenta diferencias en sus valores medios, aunque con un grado

considerable de variabilidad. Por su parte, la entropía muestra un comportamiento más similar entre las clases. Estas observaciones son exploratorias y no permiten determinar por sí solas qué características son realmente útiles para la clasificación. Por ello, posteriormente será necesario analizar la capacidad discriminativa de las características mediante métodos de selección y evaluación sobre un conjunto de datos más amplio.

Siguiente etapa: `03_Preprocesamiento.ipynb`