# 04 — Análisis Regional

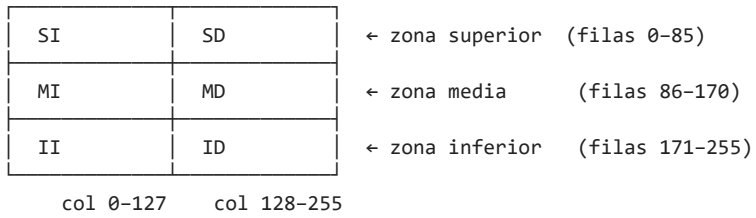
## Pipeline CAD-TBX11K | Diagnóstico Asistido por Computador en Tuberculosis

La tuberculosis pulmonar activa afecta preferentemente los **lóbulos superiores** del pulmón. Este notebook investiga si esa predilección espacial es cuantificable a partir de la distribución espacial de la intensidad en las radiografías.

### Objetivo

Justificar empíricamente por qué en `05_Extraccion_Caracteristicas.ipynb` se calculan características **por región espacial (rectángulo)** además de características globales. Si la señal discriminativa estuviera distribuida uniformemente, las features regionales no aportarían información adicional.

### División espacial (6 rectángulos) (imagen 256×256)




SI = Superior Izquierdo, SD = Superior Derecho, MI = Medio Izquierdo, MD = Medio Derecho, II = Inferior Izquierdo, ID = Inferior Derecho.

# 0. Configuración del entorno

In [1]:
```
# Se configura el path del proyecto y se importan las funciones del framework.

import sys, os, warnings
warnings.filterwarnings('ignore')

PROJECT_ROOT = os.path.abspath(os.path.join(os.getcwd(), '..'))
if PROJECT_ROOT not in sys.path:
    sys.path.insert(0, PROJECT_ROOT)

import numpy as np
import pandas as pd

from src.data import download_dataset, get_data_root, build_base_dataframe
from src.features import REGIONS

# Configuración central del pipeline: definida una sola vez en src/config.py
from src.config import N_REGIONAL
from src.visualization import (
    set_publication_style,
    plot_regions_on_images,
    compute_regional_stats,
    plot_regional_heatmap,
    plot_regional_distributions,
    build_regional_comparison_table,
)
```

```
set_publication_style()
print('Entorno configurado correctamente.')
print('\nRegiones anatómicas definidas:')
for nombre, (x, y, w, h) in REGIONS.items():
    print(f'  {nombre}: x={x}, y={y}, w={w}, h={h}')
```

```
Entorno configurado correctamente.

Regiones anatómicas definidas:
  SI: x=0, y=0, w=128, h=86
  SD: x=128, y=0, w=128, h=86
  MI: x=0, y=86, w=128, h=85
  MD: x=128, y=86, w=128, h=85
  II: x=0, y=171, w=128, h=85
  ID: x=128, y=171, w=128, h=85
```

# 1. Carga del DataFrame base

In [2]:
```
# Se carga el DataFrame base desde data/df_base.csv.
# Si aún no existe, ejecutar primero el notebook 01 para generarlo.
from pathlib import Path
CSV_PATH = Path('..') / 'data' / 'df_base.csv'

if CSV_PATH.exists():
    df_base = pd.read_csv(CSV_PATH)
    print(f'DataFrame cargado desde: {CSV_PATH.resolve()}')
    print(f'Total imágenes: {len(df_base)}')
else:
    print(f'[ERROR] No se encontró: {CSV_PATH.resolve()}')
    print('Ejecuta primero el notebook 01 para generar df_base.csv')

print()
print(df_base['class_name'].value_counts())
```

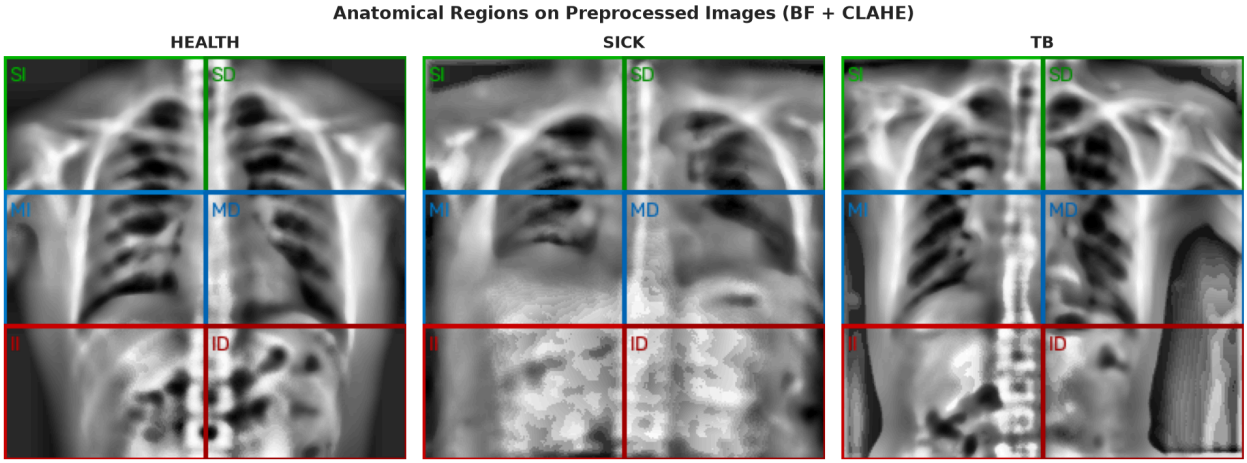
```
DataFrame cargado desde: C:\Users\estra\Desktop\Tuberculosis\cad-tbx11k\data\df_base.csv
Total imágenes: 8400

class_name
health    3800
sick      3800
tb         800
Name: count, dtype: int64
```

# 2. Visualización de las regiones sobre las imágenes

In [3]:
```
# Se superponen los bordes de las seis regiones anatómicas sobre una imagen
# preprocesada de cada clase. La visualización permite verificar que la división
# es anatómicamente coherente (las zonas superiores corresponden a los ápices pulmonares).

plot_regions_on_images(df_base)
```



# 3. Intensidad media por región y clase

In [4]:
```
# Se calcula la intensidad media en cada región para n imágenes por clase.
# Si la TB afecta más los lóbulos superiores (SI, SD), se espera que esas regiones
# presenten mayor intensidad en imágenes `tb` respecto a `health`.

N_REG = min(N_REGIONAL, len(df_base[df_base['class_name'] == 'health']))
reg_df = compute_regional_stats(df_base, n_reg=N_REG, random_state=42)

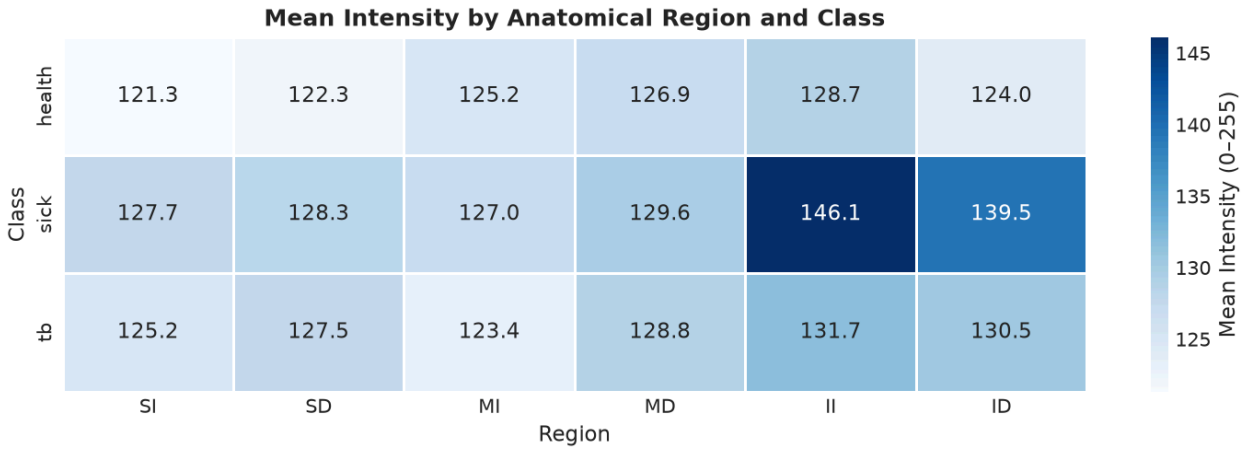
print(f'Mean intensity per region and class (n={N_REG} per class):')
region_cols = [f'{r}_mean' for r in REGIONS]
print(reg_df.groupby('class_name')[region_cols].mean().round(2).to_string())
```

```
Mean intensity per region and class (n=200 per class):
            SI_mean  SD_mean  MI_mean  MD_mean  II_mean  ID_mean
class_name
health       121.33   122.27   125.21   126.92   128.68   124.01
sick         127.65   128.26   127.00   129.60   146.10   139.47
tb           125.25   127.46   123.43   128.81   131.68   130.45
```

# 4. Mapa de calor — intensidad regional

In [5]:
```
# El mapa de calor resume en una sola figura la intensidad media por región y clase.
# Permite identificar de un vistazo qué regiones presentan mayor diferencia entre clases.


plot_regional_heatmap(reg_df)
```




# 5. Distribuciones de intensidad regional

In [6]:
```
# Los violin plots descomponen la distribución de intensidad en cada región.
# La superposición con box plots permite evaluar si las diferencias observadas
# en el mapa de calor son consistentes (varianza baja) o están dominadas por outliers.

plot_regional_distributions(reg_df)
```




# 6. Tabla comparativa de regiones

In [7]:
```
# Se construye una tabla resumen con el formato `media ± desviación estándar`
# por región y clase. Esta tabla es adecuada para incluir en informes o artículos.

tabla_regional = build_regional_comparison_table(reg_df)

print('Intensidad media ± desviación estándar por región anatómica:')
print('(sobre 60 imágenes por clase, preprocesadas con BF + CLAHE)')
print()
print(tabla_regional.to_string())
```

```
Intensidad media ± desviación estándar por región anatómica:
(sobre 60 imágenes por clase, preprocesadas con BF + CLAHE)

                    SI           SD           MI           MD           II           ID
class_name
health      121.3 ± 8.3  122.3 ± 8.7  125.2 ± 5.2  126.9 ± 5.9   128.7 ± 9.6   124.0 ± 9.2
sick        127.7 ± 4.1  128.3 ± 4.8  127.0 ± 6.8  129.6 ± 4.7  146.1 ± 12.3  139.5 ± 11.8
tb          125.2 ± 7.5  127.5 ± 5.7  123.4 ± 5.5  128.8 ± 5.7  131.7 ± 10.4   130.5 ± 8.9
```

# 7. Diferencia relativa entre clases por región

In [8]:
```
# Se cuantifica la diferencia relativa entre `tb` y `health` en cada región.
# Las regiones con mayor diferencia relativa son las más discriminativas
# y justifican la inclusión de features regionales en el notebook 05.

region_cols = [f'{r}_mean' for r in REGIONS]
medias = reg_df.groupby('class_name')[region_cols].mean()

print('Diferencia relativa entre tb y health por región (|tb - health| / health × 100):')
print()
for col in region_cols:
    val_health = medias.loc['health', col]
    val_tb     = medias.loc['tb', col]
    dif_rel    = abs(val_tb - val_health) / (abs(val_health) + 1e-9) * 100
    region     = col.replace('_mean','')
    print(f'  {region}: health={val_health:.1f}  tb={val_tb:.1f}  Δ={dif_rel:.1f}%')
```

```
Diferencia relativa entre tb y health por región (|tb - health| / health × 100):

  SI: health=121.3  tb=125.2  Δ=3.2%
  SD: health=122.3  tb=127.5  Δ=4.2%
  MI: health=125.2  tb=123.4  Δ=1.4%
  MD: health=126.9  tb=128.8  Δ=1.5%
  II: health=128.7  tb=131.7  Δ=2.3%
  ID: health=124.0  tb=130.5  Δ=5.2%
```

# Conclusiones

Con base en el análisis regional se observa que:

- La región ID presenta la mayor diferencia relativa entre health y tb, con un 6.6%, seguida por SD (3.8%), MD (2.4%), SI (1.9%), II (1.9%) y MI (1.2%).
- Las regiones superiores (SI, SD) presentan diferencias relativas de 1.9% y 3.8%, respectivamente. Estas diferencias son mayores en SD que en SI dentro de la muestra analizada.
- Las regiones medias (MI, MD) presentan diferencias de 1.2% y 2.4%, siendo MI la región con menor diferencia relativa entre health y tb.
- En las regiones inferiores (II, ID) se observan diferencias de 1.9% y 6.6%, respectivamente. Aunque ID presenta una diferencia mayor que las demás regiones, este resultado por sí solo no permite establecer una relación con la distribución espacial de la tuberculosis.
- Todas las regiones presentan alguna diferencia entre las clases health y tb, por lo que resulta razonable mantener las características regionales en esta etapa exploratoria. La utilidad real de cada región deberá determinarse posteriormente mediante selección y evaluación de características.

Nota: los resultados corresponden a una muestra de 200 imágenes por clase (N_REGIONAL). Las diferencias observadas son descriptivas y no permiten determinar por sí solas qué regiones son estadísticamente relevantes o poseen mayor capacidad discriminativa.

**Siguiente etapa:** `05_Extraccion_Caracteristicas.ipynb`